# Stratus - Dokumentacija ML Modela

Podaci, priprema, treniranje i evaluacija modela za predviđanje kašnjenja letova

## 1. Definicija problema

Model prije polaska, na osnovu podataka o letu i vremena na polaznom aerodromu, procjenjuje kako će se let završiti. Problem je postavljen kao **višeklasna klasifikacija** sa četiri klase: na vrijeme, manje kašnjenje, značajno kašnjenje i otkazan/preusmjeren let. Klasifikacija je odabrana umjesto predviđanja tačnog broja minuta jer otkazan let nema vrijednost kašnjenja, a korisniku je bitna procjena rizika, a ne precizan broj minuta. Model za svaki let vraća vjerovatnoću svake klase.

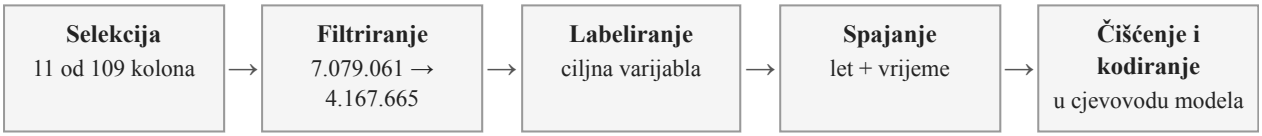
## 2. Skupovi podataka

**BTS Airline On-Time Performance.**[1] Državna baza podataka o domaćim letovima u SAD. Za 2024. godinu preuzeto je 12 mjesečnih arhiva sa ukupno **7.079.061 letova** i 109 kolona.

**Open-Meteo ERA5 arhiva.**[2] Satni historijski vremenski podaci za 50 aerodroma za cijelu 2024. godinu (439.200 zapisa): temperatura, padavine, snijeg, brzina vjetra i oblačnost. Isti servis nudi i prognozu sa istim varijablama, pa se u aplikaciji koristi isti izvor kao pri treniranju.

Nijedan izvor nije gotov skup za učenje: ne postoji ciljna varijabla, a podaci o letovima ne sadrže vremenske uslove.

## 3. Priprema podataka




*Slika 1. Tok pripreme podataka*

### 3.1. Selekcija i filtriranje

Zadržane su samo kolone **poznate prije polaska** (datum, aviokompanija, aerodromi, vrijeme polaska, udaljenost) i tri kolone potrebne za ciljnu varijablu. Kolone poput stvarnog vremena polijetanja su izostavljene jer su poznate tek nakon leta i dale bi lažno visoku tačnost. Zadržani su samo letovi između **50 najprometnijih aerodroma**, jer manji aerodromi imaju premalo letova za učenje. Rezultat je **4.167.665 letova**.

### 3.2. Ciljna varijabla

Ciljna varijabla ne postoji u sirovim podacima, nego je izvedena iz tri kolone: minuti kašnjenja pri dolasku, oznaka otkazivanja i oznaka preusmjeravanja. Prag od 15 minuta je zvanična BTS definicija leta na vrijeme.[1]

| Klasa | Naziv | Pravilo | Udio letova |
|---|---|---|---|
| 1 | Na vrijeme | kašnjenje do 15 min | 77,81 % |
| 2 | Manje kašnjenje | kašnjenje 15-60 min | 13,27 % |
| 3 | Značajno kašnjenje | kašnjenje preko 60 min | 7,31 % |
| 4 | Otkazan ili preusmjeren | let otkazan ili preusmjeren | 1,6 % |

*Tabela 1. Klase i njihov udio u skupu*

Otkazani i preusmjereni letovi nemaju zabilježeno kašnjenje (66.720 letova), pa se u klasu 4 svrstavaju tek nakon primjene pragova u minutama. U suprotnom bi bili pogrešno označeni kao letovi na vrijeme. Ovo je bio jedini slučaj nedostajućih podataka u skupu.

### 3.3. Spajanje sa vremenskim podacima

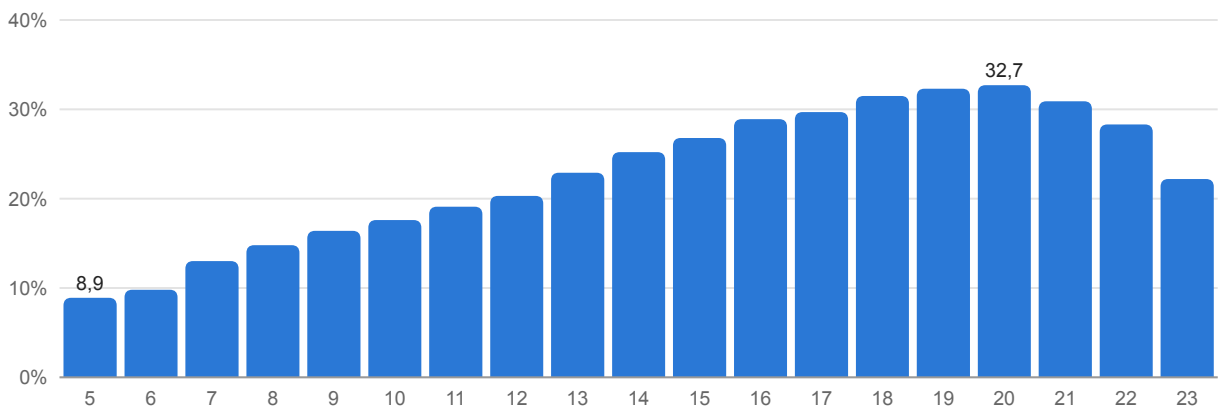
Iz vremena polaska (format *hhmm*, npr. 1735) izveden je **sat polaska**. Svaki let je zatim spojen sa vremenom na polaznom aerodromu **u satu polaska**, po lokalnom vremenu tog aerodroma, jer BTS vrijeme polaska izražava u lokalnom vremenu. Svi letovi su pronašli odgovarajući vremenski zapis. Model koristi 12 atributa:

| Grupa | Atributi | Izvor |
|---|---|---|
| Let (kategorijski) | aviokompanija, polazni aerodrom, dolazni aerodrom | BTS |
| Let (numerički) | mjesec, dan u sedmici, sat polaska, udaljenost | BTS |
| Vrijeme (numerički) | temperatura, padavine, snijeg, brzina vjetra, oblačnost | Open-Meteo |

*Tabela 2. Ulazni atributi modela*

### 3.4. Eksplorativna analiza

Analiza je potvrdila da atributi nose informaciju o ishodu. Udio letova sa kašnjenjem raste tokom dana (slika 2), jer se kašnjenja lančano prenose sa leta na let.[5] Najviše kašnjenja ima u julu (32,8 %), a najmanje u oktobru (14,1 %). Pri padavinama iznad 5 mm/h kasni 50 % letova, a pri snijegu iznad 1 cm/h otkazano je 20 % letova, u odnosu na 1,6 % bez snijega.




*Slika 2. Udio letova sa kašnjenjem ili otkazivanjem po satu polaska*

## 4. Transformacije i podjela podataka

Transformacije su ugrađene u **cjevovod** (*pipeline*)[4] koji se trenira zajedno sa modelom:

- numerički atributi: popunjavanje praznih vrijednosti medijanom i standardizacija,
- kategorijski atributi: **one-hot kodiranje**, gdje svaka aviokompanija i aerodrom dobija svoju kolonu (124 atributa ukupno). Redni brojevi nisu korišteni jer bi nametnuli nepostojeći poredak među aerodromima.

Iz skupa je uzet uzorak od 1.000.000 letova, podijeljen **80/20** na trening (800.000) i test (200.000). Podjela je **stratifikovana**, tako da oba dijela imaju isti udio klasa. Pošto su transformacije dio cjevovoda, uče se samo iz trening skupa, pa nema curenja informacija iz testnog skupa, a aplikacija podatke obrađuje isto kao pri treniranju.

## 5. Neuravnoteženost klasa

Pošto 77,81 % letova stiže na vrijeme, model bez korekcije gotovo uvijek predviđa klasu 1. Zato su rijetke klase dobile veće **težine** pri učenju. Korištena je blaža varijanta: korijen inverzne frekvencije klase. Tabela 3 pokazuje zašto:

| Ponderisanje | Tačnost | Prepoznato značajnih kašnjenja | Prepoznato otkazivanja |
|---|---|---|---|
| Bez ponderisanja | 78,0 % | 3 % | 6 % |
| **Korijen inverzne frekvencije (odabrano)** | **75,5 %** | **18 %** | **19 %** |
| Puna inverzna frekvencija | 53,3 % | 38 % | 49 % |

*Tabela 3. Uticaj ponderisanja (trening na 300.000 letova)*

Bez ponderisanja model ignoriše kašnjenja i otkazivanja, a sa punim ponderisanjem tačnost pada na 53 %. Odabrana varijanta je kompromis.

## 6. Model: XGBoost

XGBoost[3] gradi niz stabala odlučivanja, gdje svako novo stablo ispravlja greške prethodnih. Odabran je zato što:

- na tabelarnim podacima modeli zasnovani na stablima u pravilu daju najbolje rezultate,
- sam uči nelinearne veze i interakcije (npr. snijeg je problem u Chicagu, a ne u Miamiju),
- podržava težine klasa i vraća vjerovatnoće,
- brzo se trenira na velikom skupu podataka,
- u poređenju sa drugim modelima na istim podacima dao je najbolje rezultate (tabela 5).

| Hiperparametar | Vrijednost | Značenje |
|---|---|---|
| n_estimators | 300 | broj iteracija (stabala po klasi) |
| max_depth | 6 | maksimalna dubina stabla |
| learning_rate | 0,1 | doprinos svakog novog stabla |
| subsample / colsample_bytree | 0,8 | slučajni udio letova / atributa po stablu, smanjuje preprilagođavanje |

*Tabela 4. Hiperparametri modela*

## 7. Evaluacija

Zbog neuravnoteženosti klasa obična tačnost nije dovoljna, jer model koji uvijek kaže „na vrijeme“ ima 77,8 %. Zato su korištene i **balansirana tačnost** (prosječan udio prepoznatih letova po klasi, gdje nasumično pogađanje daje 25 %) i **ROC AUC** (koliko dobro vjerovatnoće razdvajaju klase, gdje 0,5 znači nasumično, a 1 savršeno).

Konačni model na 200.000 testnih letova postiže tačnost od **75,7 %**, balansiranu tačnost od **36,0 %** i ROC AUC od **0,74**. Najbolje prepoznaje otkazivanja (AUC 0,84). Tačnost je nešto niža od referentnog modela, što je očekivana posljedica ponderisanja: model se odriče dijela tačnih odgovora za klasu 1 da bi prepoznao kašnjenja i otkazivanja, koja referentni model ne prepoznaje uopšte.

### 7.1. Poređenje modela

| Model | Tačnost | Balansirana tačnost | ROC AUC | Prepoznato otkazivanja |
|---|---|---|---|---|
| Uvijek „na vrijeme“ (referentni) | 77,8 % | 25,0 % | 0,50 | 0 % |
| Logistička regresija | 76,4 % | 27,4 % | 0,66 | 2 % |
| Random Forest | 77,8 % | 28,1 % | 0,72 | 6 % |
| **XGBoost** | **75,5 %** | **35,2 %** | **0,74** | **19 %** |

*Tabela 5. Poređenje modela na istim podacima (trening na 300.000 letova)*

Random Forest ima najveću tačnost samo zato što gotovo uvijek predviđa „na vrijeme“. XGBoost je najbolji po ostalim metrikama.

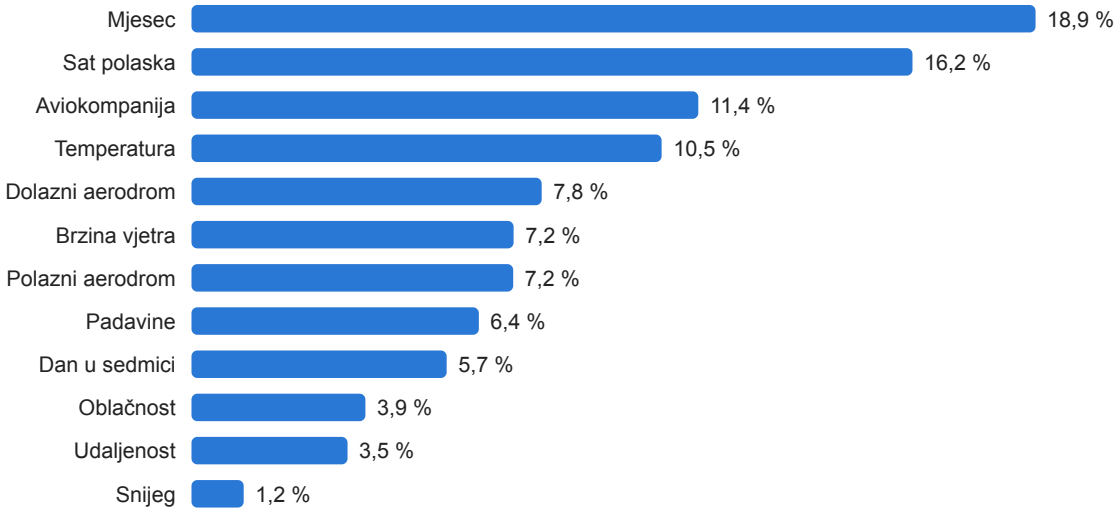
### 7.2. Doprinos vremenskih podataka

| Konfiguracija | Tačnost | Balansirana tačnost | ROC AUC | Prepoznato otkazivanja |
|---|---|---|---|---|
| **Sa vremenskim podacima** | **75,5 %** | **35,2 %** | **0,74** | **19 %** |
| Bez vremenskih podataka | 74,9 % | 32,4 % | 0,72 | 12 % |

*Tabela 6. XGBoost sa i bez vremenskih podataka*

Vremenski podaci poboljšavaju model po svim metrikama, najviše kod otkazivanja.

### 7.3. Važnost atributa




*Slika 3. Važnost atributa u modelu*

Najvažniji su mjesec i sat polaska, a vremenski atributi zajedno čine 29 % važnosti. Snijeg ima malu ukupnu važnost jer je rijedak, ali kada ga ima, snažno utiče na otkazivanja.

## 8. Ograničenja

- Model ne zna da li avion kasni sa prethodnog leta, što je najčešći uzrok kašnjenja.
- Koristi se samo vrijeme na polaznom, a ne i na dolaznom aerodromu.
- Zbog ponderisanja prikazane vjerovatnoće su pomjerene prema kašnjenjima i služe za poređenje rizika, a ne kao doslovne vjerovatnoće.
- Podjela podataka je slučajna, a ne vremenska, i hiperparametri nisu sistematski podešavani.

## 9. Zaključak

Model je razvijen iz dva sirova javna izvora: podaci o letovima su filtrirani, labelirani u četiri klase i spojeni sa satnim vremenskim podacima. XGBoost model postiže tačnost od 75,7 % i ROC AUC od 0,74, bolji je od logističke regresije i Random Foresta, a vremenski podaci ga dodatno poboljšavaju. Model služi kao alat za procjenu rizika kašnjenja, a ne kao sigurna prognoza za pojedinačni let.

## Literatura

1. U.S. Department of Transportation, Bureau of Transportation Statistics. *Airline On-Time Performance Data*. https://www.transtats.bts.gov

2. Zippenfenig, P. (2023). Open-Meteo.com Weather API. Zenodo. https://doi.org/10.5281/zenodo.7970649

3. Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD Conference*, 785-794.

4. Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

5. Rebollo, J. J., & Balakrishnan, H. (2014). Characterization and prediction of air traffic delays. *Transportation Research Part C*, 44, 231-241.

# Dio 2 - Prelazak na evropski skup podataka

Zamjena američkih BTS podataka norveškim Avinor podacima i prilagođavanje aplikacije

Prvi dio dokumentacije opisuje model treniran na podacima o domaćim letovima u SAD. Pošto je aplikacija namijenjena korisnicima u Evropi, model je ponovo treniran na **evropskom skupu podataka**. Uslov je bio da podaci budu javno dostupni i da se mogu preuzeti **bez registracije**, tako da cijeli postupak (preuzimanje, priprema, treniranje) i dalje radi jednom komandom. Ovaj dio opisuje kako je novi skup odabran, šta se u njemu razlikuje od BTS skupa i sve izmjene koje su bile potrebne u pripremi podataka, modelu i aplikaciji.

## 10. Izbor novog skupa podataka

Model za svaki let traži aviokompaniju, polazni i dolazni aerodrom, **planirano vrijeme polaska**, **planirano i stvarno vrijeme dolaska** (iz kojih se računa kašnjenje) i **oznaku otkazivanja**. Pregledani su dostupni evropski izvori:

| Izvor | Pristup | Ocjena |
|---|---|---|
| EUROCONTROL ADRR[8] | registracija, samo za istraživanje | po letu, ali samo 4 mjeseca godišnje, bez otkazanih letova, a planirano vrijeme je iz posljednjeg plana leta |
| EUROCONTROL OPDI[9] | slobodno | nema reda letenja (samo ADS-B praćenje); Sarajevo i Tuzla u junu 2024. nemaju nijedan let |
| HuggingFace „flight-delays-europe“ | slobodno | „kašnjenje“ je odstupanje trajanja leta od medijana rute, a ne od reda letenja |
| UK CAA, EUROCONTROL portal | slobodno | samo zbirni podaci (mjesečno ili dnevno po aerodromu) |
| Zürich (studentski projekat) | slobodno | samo polasci iz Züricha, 3 mjeseca, bez stvarnog vremena dolaska |
| AeroDataBox API | plaćeno | pravi red letenja, ali skupo za veliki historijski skup |
| **Avinor historical flights**[6] | **slobodno** | **odabran**: po letu, planirana i stvarna vremena, otkazivanja, 7,5 godina |

*Tabela 7. Razmatrani evropski izvori podataka*

Podaci za region (BiH i susjedne zemlje) sa redom letenja nisu javno dostupni bez registracije ili plaćanja, pa je odabran najpotpuniji evropski izvor.

# 11. Avinor skup podataka

**Avinor**, državni operater norveških aerodroma, objavio je historijske podatke o letovima za takmičenje u mašinskom učenju.[6] Skup ima **410.442 leta** od januara 2018. do jula 2025. i jednu CSV datoteku (53 MB) koja se preuzima direktno sa GitHuba. Sadrži podatke o letovima koji dotiču aerodrome iz Avinorovog projekta daljinski upravljanih kontrolnih tornjeva, pa dominiraju **kratke regionalne rute** na sjeveru i zapadu Norveške (medijan udaljenosti je 154 km) i aviokompanija Widerøe (94,2 % letova).

| Kolona | Opis |
|---|---|
| `flight_id` | broj leta; prva dva znaka su IATA kod aviokompanije (npr. WF149) |
| `dep_airport`, `arr_airport` | IATA kod polaznog i dolaznog aerodroma |
| `service_type` | vrsta leta (J = redovni putnički, C = čarter, F = teretni...) |
| `std`, `sta` | planirano vrijeme polaska i dolaska (UTC) |
| `atd`, `ata` | stvarno vrijeme polaska i dolaska (UTC) |
| `cancelled` | oznaka otkazanog leta (0/1) |

*Tabela 8. Kolone Avinor skupa korištene u pripremi podataka*

# 12. Prilagođavanje pripreme podataka




*Slika 4. Tok pripreme Avinor podataka*

### 12.1. Razlike u odnosu na BTS

Model i dalje koristi istih 12 atributa, ali Avinor podaci imaju drugačiji oblik, pa je gotovo svaki atribut trebalo izvesti na novi način:

| Podatak | BTS | Avinor | Rješenje |
|---|---|---|---|
| Vrijeme polaska | lokalno, format hhmm | UTC, datum i vrijeme | pretvoreno u lokalno vrijeme (Europe/Oslo); mjesec i dan u sedmici računaju se iz lokalnog datuma |
| Udaljenost | kolona u miljama | ne postoji | izračunata iz koordinata aerodroma (ortodroma), izvor koordinata OurAirports[7] |
| Aviokompanija | posebna kolona | dio broja leta | prva dva znaka broja leta; ICAO prefiks „LPA“ mapiran na FL (Air Leap) |
| Kašnjenje | gotova kolona u minutama | ne postoji | stvarni minus planirani dolazak (`ata − sta`) |
| Preusmjeren let | posebna oznaka | ne postoji | klasa 4 sada znači samo „Otkazan“ |
| Aerodromi | 50 najprometnijih u SAD | oko 120 aerodroma | zadržano 36 norveških aerodroma sa najmanje 500 letova |

*Tabela 9. Razlike između BTS i Avinor podataka i način prilagođavanja*

Dokumentacija skupa ne navodi vremensku zonu. Da su vremena u UTC-u potvrđeno je provjerom: isti redovni let ljeti polijeće sat ranije nego zimi, što odgovara prelasku Norveške na ljetno računanje vremena. Da je vrijeme u lokalnoj zoni, sat polaska bi ostao isti.

### 12.2. Filtriranje i čišćenje

- Zadržani su samo **redovni putnički letovi** (`service_type = J`), između 36 odabranih aerodroma i od 5 aviokompanija: Widerøe (WF), Norwegian (DY), SAS (SK), Air Leap (FL) i DAT (DX).
- Izbačena su **42 leta** kojima je polazni aerodrom isti kao dolazni (greška u podacima). Rezultat filtriranja je **406.688 letova**.
- Izbačeno je **5.315 letova** koji nisu otkazani, a nemaju stvarno vrijeme dolaska ili imaju nemoguće vrijeme (više od 2 sata prije plana ili više od 24 sata kasnije; najekstremniji zapis je 27.312 minuta prije plana). Za razliku od BTS skupa, ovdje se nedostajuće vrijeme dolaska ne tumači kao let na vrijeme, jer ishod leta nije poznat.

Konačni skup ima **401.373 leta**, što je ispod ograničenja od 1.000.000, pa se za treniranje koriste svi letovi.

### 12.3. Spajanje sa vremenskim podacima

Preuzeti su satni podaci sa Open-Meteo arhive[2] za 36 aerodroma za period od 31. 12. 2017. do 1. 8. 2025. (**2.394.144 zapisa**). Jedan zahtjev za 7,5 godina podataka troši oko 100 poziva besplatnog limita, pa je preuzimanje prekinuto nakon 12 aerodroma. Zato se podaci sada čuvaju

posebno za svaki aerodrom, a skripta nakon prekoračenja limita čeka 70 sekundi i nastavlja gdje je stala. Pri jesenskom prelasku na zimsko računanje vremena jedan lokalni sat se ponavlja, pa je za taj sat zadržan jedan zapis. **Svi letovi** su pronašli odgovarajući vremenski zapis.

## 13. Klase u novom skupu

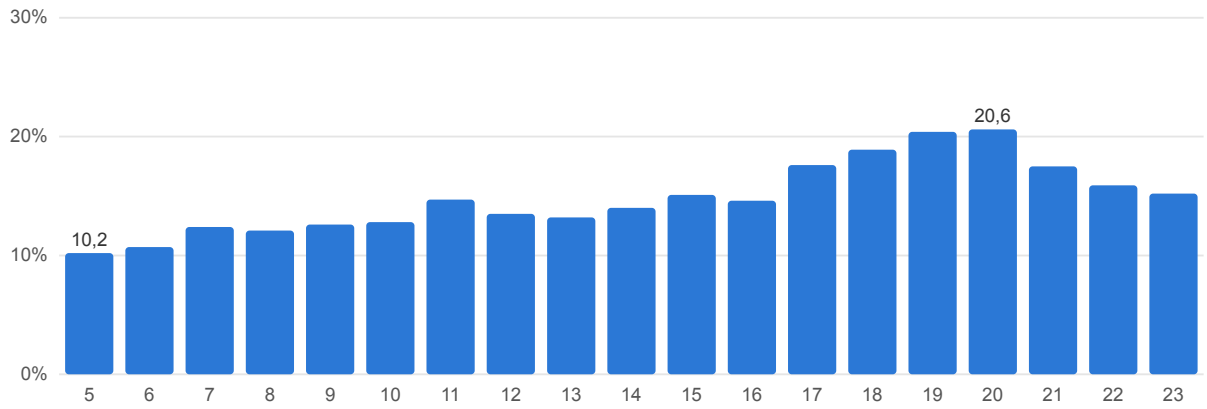
| Klasa | Naziv | Broj letova | Udio (Avinor) | Udio (BTS) |
|---|---|---|---|---|
| 1 | Na vrijeme | 341.061 | 84,97 % | 77,81 % |
| 2 | Manje kašnjenje | 42.378 | 10,56 % | 13,27 % |
| 3 | Značajno kašnjenje | 7.305 | 1,82 % | 7,31 % |
| 4 | Otkazan | 10.629 | 2,65 % | 1,60 % |

*Tabela 10. Klase u Avinor skupu u poređenju sa BTS skupom*

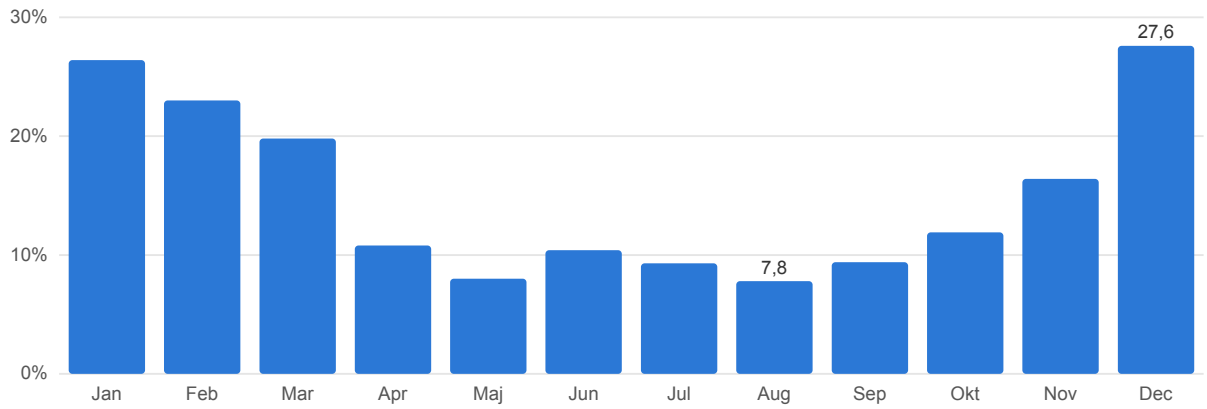
Norveški regionalni letovi češće stižu na vrijeme, a značajna kašnjenja su četiri puta rjeđa nego u SAD. S druge strane, otkazivanja su češća, jer se na malim aerodromima po lošem vremenu let češće otkaže nego odgodi. Neuravnoteženost klasa je zato još izraženija nego u prvom dijelu.

## 14. Eksplorativna analiza

Kao i u SAD, udio letova sa kašnjenjem ili otkazivanjem raste tokom dana, sa 10,2 % u 5 sati na 20,6 % u 20 sati (slika 5), ali je rast blaži. Glavna razlika je **godišnje doba**: u SAD je najviše problema bilo u julu, a u Norveškoj zimi. U decembru (27,6 %) i januaru (26,4 %) problema ima više od tri puta više nego u augustu (7,8 %), što je prikazano na slici 6.




*Slika 5. Udio letova sa kašnjenjem ili otkazivanjem po satu polaska*




*Slika 6. Udio letova sa kašnjenjem ili otkazivanjem po mjesecu*

Vremenski uslovi imaju snažan uticaj na otkazivanja:

- pri vjetru jačem od 50 km/h otkazano je **25,1 %** letova, u odnosu na 2,5 % pri vjetru do 30 km/h (557 letova),
- pri snijegu iznad 1 cm/h otkazano je **11,5 %** letova, u odnosu na 2,2 % bez snijega (1,779 letova),
- pri padavinama iznad 5 mm/h kasni ili je otkazano 22,6 % letova, u odnosu na 11,6 % bez padavina (samo 297 letova).

## 15. Treniranje i evaluacija na novom skupu

Cjevovod, model i hiperparametri su isti kao u prvom dijelu (tabela 4). Skup je podijeljen stratifikovano 80/20 na **321,098** trening i **80,275** testnih letova. Sve vrijednosti u ovom poglavlju izračunate su na istoj podjeli. One-hot kodiranje sada daje 86 atributa (36 + 36 aerodroma, 5 aviokompanija i 9 numeričkih).

### 15.1. Neuravnoteženost klasa

| Ponderisanje | Tačnost | Balansirana tačnost | Prepoznato značajnih kašnjenja | Prepoznato otkazivanja |
|---|---|---|---|---|
| Bez ponderisanja | 85,3 % | 27,3 % | 1 % | 4 % |
| **Korijen inverzne frekvencije (odabrano)** | **83,2 %** | **33,9 %** | **7 %** | **11 %** |
| Puna inverzna frekvencija | 56,6 % | 43,4 % | 37 % | 41 % |

*Tabela 11. Uticaj ponderisanja na Avinor skupu*

Zaključak je isti kao u prvom dijelu: bez ponderisanja model gotovo nikad ne predviđa kašnjenje ni otkazivanje, a puno ponderisanje ruši tačnost na 56,6 %. Zadržana je ista kompromisna varijanta.

### 15.2. Poređenje modela

| Model | Tačnost | Balansirana tačnost | ROC AUC | Prepoznato otkazivanja |
|---|---|---|---|---|
| Uvijek „na vrijeme“ (referentni) | 85,0 % | 25,0 % | 0,50 | 0 % |
| Logistička regresija | 84,1 % | 28,9 % | 0,69 | 5 % |
| Random Forest | 84,2 % | 31,5 % | 0,74 | 8 % |
| **XGBoost** | **83,2 %** | **33,9 %** | **0,75** | **11 %** |

*Tabela 12. Poređenje modela na Avinor skupu (svi modeli sa istim ponderisanjem)*

XGBoost je ponovo najbolji po balansiranoj tačnosti, ROC AUC-u i prepoznavanju otkazivanja. Tačnost svih modela je nešto ispod referentnog modela iz istog razloga kao u prvom dijelu: ponderisanje žrtvuje dio tačnih odgovora za klasu 1.

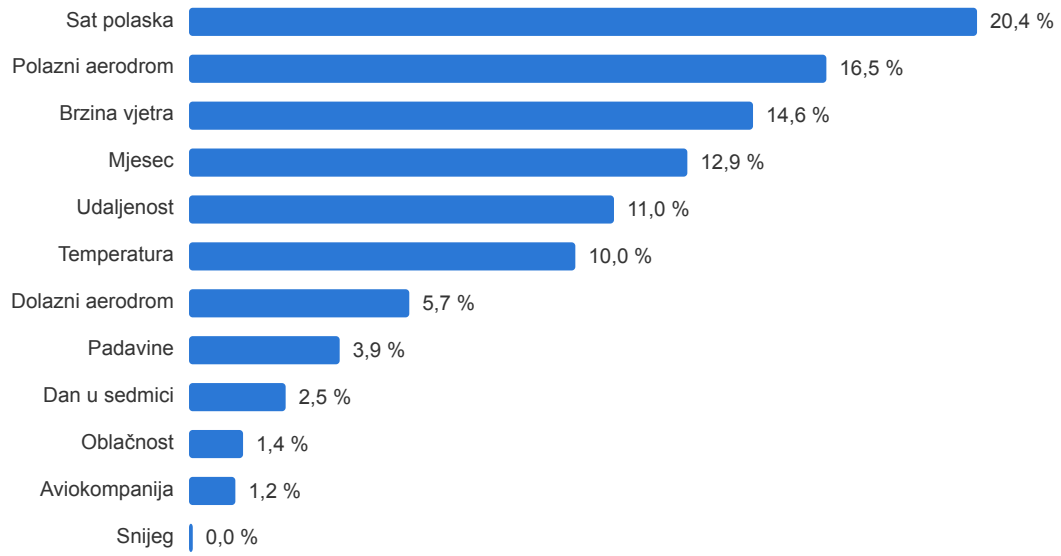
### 15.3. Doprinos vremenskih podataka

| Konfiguracija | Tačnost | Balansirana tačnost | ROC AUC | Prepoznato otkazivanja |
|---|---|---|---|---|
| Sa vremenskim podacima | 83,2 % | 33,9 % | 0,75 | 11 % |
| Bez vremenskih podataka | 82,8 % | 29,3 % | 0,71 | 5 % |

*Tabela 13. XGBoost sa i bez vremenskih podataka na Avinor skupu*

Vremenski podaci su na norveškim podacima važniji nego na američkim: bez njih model prepoznaje upola manje otkazivanja, a ROC AUC pada sa 0,75 na 0,71.

### 15.4. Važnost atributa




*Slika 7. Permutacijska važnost atributa (porast log-loss greške na testnom skupu)*

Važnost je ovdje mjerena **permutacijom**: vrijednosti jednog atributa se nasumično izmiješaju i mjeri se koliko se greška modela poveća. Ugrađena mjera XGBoosta sabira sve one-hot kolone

jednog atributa i zato bi aerodromima pripisala čak 78 % važnosti. Najvažniji su sat polaska, polazni aerodrom i brzina vjetra, a vremenski atributi zajedno čine 29,9 % važnosti. Snijeg ima važnost blizu nule jer je rijedak (manje od 0,5 % letova ima snijeg iznad 1 cm/h), a dio iste informacije već nose temperatura i padavine.

### 15.5. Poređenje sa modelom iz prvog dijela

| Metrika | BTS model (SAD) | Avinor model (Norveška) |
|---|---|---|
| Broj letova u skupu | 4.167.665 | 401.373 |
| Tačnost referentnog modela | 77,8 % | 85,0 % |
| Tačnost | 75,7 % | 83,2 % |
| Balansirana tačnost | 36,0 % | 33,9 % |
| ROC AUC | 0,74 | 0,75 |

*Tabela 14. Konačni model na BTS i na Avinor skupu*

Veća tačnost novog modela uglavnom dolazi od toga što u Norveškoj više letova stiže na vrijeme, pa je i referentni model tačniji. Razdvajanje klasa (ROC AUC) je na sličnom nivou, a balansirana tačnost je nešto niža jer su značajna kašnjenja mnogo rjeđa i model ih teže prepoznaje.

## 16. Izmjene u aplikaciji

Ulaz i izlaz modela su ostali isti (12 atributa, 4 klase), pa API i logika forme nisu mijenjani. Prognoza vremena sa Open-Meteo servisa radi i za norveške aerodrome bez izmjena. Izmijenjeni su podaci, priprema i tekstovi:

| Dio | Datoteka | Izmjena |
|---|---|---|
| Backend | `ml/download_data.py` | preuzima Avinor CSV (vezan za tačan commit, da se podaci ne mijenjaju), filtrira letove, preuzima vrijeme po aerodromu uz keširanje i čekanje na limit |
| | `ml/airports.py` | 36 norveških aerodroma sa koordinatama, 5 aviokompanija, funkcija za udaljenost rute |
| | `ml/train_real.py` | nova priprema: UTC u lokalno vrijeme, udaljenost, labeliranje iz `ata − sta`, čišćenje neispravnih zapisa |
| | `ml/preprocessing.py`, `ml/predict.py` | klasa 4 bez preusmjeravanja i novi naziv „Otkazan“; uklonjena konverzija milja u kilometre |
| | `ml/generate_data.py` | sintetičke udaljenosti prilagođene norveškim rutama (40-1.500 km) |
| | `app/routes/delay.py`, `app/main.py` | primjeri u opisu API polja (WF, OSL, BOO); CORS dozvoljava i port 5174 |
| | `.env.example` | uklonjene postavke godine i mjeseci BTS podataka |
| Frontend | `constants/airports.ts`, `airlines.ts` | nove liste aerodroma (sa koordinatama za udaljenost) i aviokompanija |
| | `constants/delay.tsx`, `lib/print-report.ts` | naziv klase 4 „Otkazan“ u rezultatu i izvještaju za štampu |
| | `HelpPanel.tsx`, `FlightForm.tsx` | tekstovi pomoći i primjer broja leta (WF 149) |
| Ostalo | `README.md`, `dataset/` | opis novog skupa i novi uzorak od 1.000 letova |

*Tabela 15. Izmjene u kodu aplikacije*

Postupak pokretanja je isti kao ranije (`python -m ml.download_data`, pa `python -m ml.train_real`). Stari BTS podaci i stari model sačuvani su u folderu `backend/ml/data/bts_2024/`.

## 17. Ograničenja novog skupa

- Skup nije reprezentativan za cijelu Norvešku ni za Evropu: 94,2 % letova je Widerøeovih, uglavnom sa malih regionalnih aerodroma. Model ne poznaje aerodrome izvan liste (npr. Sarajevo).
- Nema podataka o preusmjerenim letovima, pa model predviđa samo otkazivanje.
- Značajna kašnjenja su rijetka (1,82 %), pa ih model prepoznaje u samo 7 % slučajeva.
- Period uključuje pandemiju COVID-19 (2020-2021) sa neuobičajenim saobraćajem.
- Repozitorij sa podacima ne navodi licencu, pa se podaci koriste samo u akademske svrhe, uz navođenje Avinora kao izvora.
- Ograničenja iz prvog dijela (poglavlje 8) i dalje vrijede.

## 18. Zaključak

Model je uspješno prebačen sa američkih na evropske podatke bez promjene modela i interfejsa aplikacije. Najveći dio posla bio je u pripremi podataka: vremena su pretvorena iz UTC-a u lokalno vrijeme, udaljenost i kašnjenje su izračunati jer ih skup ne sadrži, a neispravni zapisi su uklonjeni. Novi model postiže tačnost od 83,2 % i ROC AUC od 0,75. Vremenski podaci su ovdje još važniji nego u SAD, posebno vjetar i zimski uslovi, koji najviše utiču na otkazivanja.

## Literatura (nastavak)


6. Avinor AS (2025). *Historical flights dataset* (historical_flights.csv), Avinor remote towers ML competition. Preuzeto iz https://github.com/MiladTootoonchi/Avinor-Predictions

7. OurAirports. *Open data downloads: airports* (javno vlasništvo). https://ourairports.com/data/

8. EUROCONTROL. *Aviation Data Repository for Research*. https://www.eurocontrol.int/dashboard/aviation-data-research

9. EUROCONTROL. *Open Performance Data Initiative (OPDI)*. https://www.opdi.aero

# Dio 3 - Iteracija 3: omjer podjele podataka

Uticaj omjera trening i testnog skupa na Avinor model

U prve dvije iteracije podaci su dijeljeni u omjeru **80:20** (80 % za trening, 20 % za test), bez provjere da li bi neki drugi omjer dao bolji model. U trećoj iteraciji ispitano je kako omjer utiče na rezultate i odabran je novi omjer. Skup podataka, atributi, model, hiperparametri i ponderisanje klasa ostali su isti kao u drugom dijelu.

## 19. Postavka eksperimenta

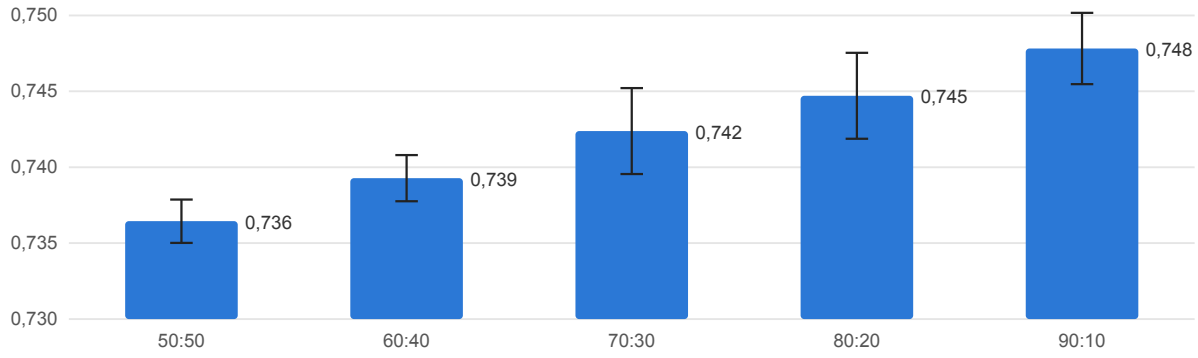
Omjer određuje kompromis između dva cilja: veći trening skup daje modelu više primjera za učenje, a veći testni skup daje pouzdaniju procjenu kvaliteta modela. Ispitano je pet omjera: **50:50, 60:40, 70:30, 80:20 i 90:10**.

- Svaki omjer je ponovljen sa **5 različitih nasumičnih podjela** (random_state 0-4), jer razlike između omjera mogu biti manje od razlika koje nastaju samo zbog toga koji su letovi slučajno završili u testnom skupu. Rezultati su prikazani kao prosjek ± standardna devijacija.
- Sve podjele su stratifikovane, tako da trening i test imaju isti udio klasa.
- Težine klasa (korijen inverzne frekvencije) računaju se iz trening dijela svake podjele.
- Mjerene su iste metrike kao ranije: tačnost, balansirana tačnost, ROC AUC i udio prepoznatih značajnih kašnjenja i otkazivanja. Mjerena je i tačnost na trening skupu, da bi se vidjelo preprilagođavanje.

## 20. Rezultati

| Omjer | Trening | Test | Tačnost | Balansirana tačnost | ROC AUC | Prepoznato značajnih kašnjenja | Prepoznato otkazivanja |
|---|---|---|---|---|---|---|---|
| 50:50 | 200.686 | 200.687 | 82,98 ± 0,09 % | 33,23 ± 0,15 % | 0,736 ± 0,001 | 5,4 % | 11,1 % |
| 60:40 | 240.823 | 160.550 | 83,00 ± 0,04 % | 33,26 ± 0,13 % | 0,739 ± 0,002 | 5,3 % | 11,1 % |
| 70:30 | 280.961 | 120.412 | 83,04 ± 0,08 % | 33,36 ± 0,13 % | 0,742 ± 0,003 | 5,4 % | 11,2 % |
| 80:20 | 321.098 | 80.275 | 83,12 ± 0,09 % | 33,48 ± 0,15 % | 0,745 ± 0,003 | 5,5 % | 11,6 % |
| **90:10** | **361.235** | **40.138** | **83,10 ± 0,09 %** | **33,61 ± 0,21 %** | **0,748 ± 0,002** | **5,5 %** | **12,0 %** |

*Tabela 16. Rezultati po omjeru podjele (prosjek ± standardna devijacija za 5 nasumičnih podjela)*




*Slika 8. ROC AUC po omjeru podjele (linije pokazuju ± jednu standardnu devijaciju)*

Sa više podataka za trening model je dosljedno nešto bolji: ROC AUC raste sa 0,736 (50:50) na 0,748 (90:10), balansirana tačnost sa 33,23 % na 33,61 %, a prepoznato otkazivanja sa 11,1 % na 12,0 %. Tačnost se gotovo ne mijenja (oko 83 %). Razlike su ipak male: između susjednih omjera iznose otprilike jednu standardnu devijaciju, pa omjer podjele **nije ključan faktor** za kvalitet ovog modela. Razlog je veličina skupa: i sa 50:50 model ima preko 200.000 letova za učenje.

### 20.1. Preprilagođavanje

| Omjer | Tačnost na trening skupu | Tačnost na testnom skupu | Razlika |
|---|---|---|---|
| 50:50 | 85,15 % | 82,98 % | 2,17 p.p. |
| 60:40 | 84,88 % | 83,00 % | 1,88 p.p. |
| 70:30 | 84,68 % | 83,04 % | 1,64 p.p. |
| 80:20 | 84,55 % | 83,12 % | 1,43 p.p. |
| 90:10 | 84,43 % | 83,10 % | 1,33 p.p. |

*Tabela 17. Tačnost na trening i testnom skupu po omjeru*

Sa većim trening skupom razlika između tačnosti na trening i testnom skupu se smanjuje sa 2,17 na 1,33 procentna poena, što znači da model manje „pamti“ trening letove i bolje generalizuje. U svim slučajevima razlika je mala, pa model nije značajno preprilagođen.

### 20.2. Pouzdanost testnog skupa

Nedostatak omjera 90:10 je manji testni skup, pa je procjena kvaliteta nešto manje stabilna: standardna devijacija balansirane tačnosti raste sa 0,15 na 0,21 procentna poena. Testni skup od **40.138 letova** je ipak dovoljno velik: sadrži 730 značajnih kašnjenja i 1.063 otkazana leta, pa se i rijetke klase mogu pouzdano ocijeniti.

## 21. Dodatno: vremenska podjela

Nasumična podjela miješa letove iz svih godina, pa model pri testiranju „poznaje“ i dane iz kojih dolaze testni letovi. U stvarnoj upotrebi model predviđa buduće letove. Zato je dodatno ispitana **vremenska podjela**: trening na letovima do kraja 2023. (317.923 letova), test na letovima iz 2024. i 2025. (83.450 letova, omjer približno 79:21).

| Podjela | Tačnost | Balansirana tačnost | ROC AUC | Prepoznato značajnih kašnjenja | Prepoznato otkazivanja |
|---|---|---|---|---|---|
| Nasumična 80:20 (prosjek) | 83,1 % | 33,5 % | 0,745 | 5,5 % | 11,6 % |
| Vremenska (do 2023. / 2024-2025.) | 81,1 % | 32,6 % | 0,709 | 4,1 % | 10,8 % |

*Tabela 18. Nasumična i vremenska podjela*

Na novijim letovima model je slabiji (ROC AUC 0,709 umjesto 0,745). Dio razloga je u samim podacima: 2024. i 2025. su imale više problema nego ranije godine. Na vrijeme je stiglo 83,0 % letova (ranije 85,5 %), značajnih kašnjenja je bilo 2,42 % (ranije 1,66 %), a otkazivanja 3,68 % (ranije 2,38 %). Rezultat vremenske podjele je zato **realnija procjena** kvaliteta modela na budućim letovima, a rezultati nasumične podjele su nešto optimistični. Vremenska podjela nije uzeta za konačni model, jer bi tada model učio samo na starijim podacima, bez najnovijih letova.

## 22. Odluka i izmjene

Za konačni model odabran je omjer **90:10**: daje najveći ROC AUC i balansiranu tačnost, najmanje preprilagođavanje, a testni skup je i dalje dovoljno velik. U kodu je izmijenjena samo jedna vrijednost: u `backend/ml/train_real.py` dodana je konstanta `TEST_SIZE = 0.1` (ranije `test_size=0.2`). Model je ponovo treniran i sačuvan u `ml/delay_model.joblib`, a tačnost u `README.md` je ažurirana.

| Konačni model | Trening / test | Tačnost | Balansirana tačnost | ROC AUC | Prepoznato otkazivanja |
|---|---|---|---|---|---|
| Iteracija 2 (80:20) | 321.098 / 80.275 | 83,2 % | 33,9 % | 0,747 | 11 % |
| **Iteracija 3 (90:10)** | **361.235 / 40.138** | **83,3 %** | **34,3 %** | **0,751** | **12 %** |

*Tabela 19. Konačni model prije i poslije promjene omjera (random_state 42)*

Dva konačna modela su ocijenjena na različitim testnim skupovima, pa njihovo direktno poređenje nije potpuno pošteno. Pouzdanije poređenje omjera daje tabela 16, gdje je svaki omjer ocijenjen na pet podjela.

## 23. Zaključak iteracije 3

Promjena omjera sa 80:20 na 90:10 donosi malo, ali dosljedno poboljšanje (ROC AUC +0,003, balansirana tačnost +0,1 do +0,4 procentna poena). Omjer podjele nije veliki izvor poboljšanja, jer je skup podataka dovoljno velik za sve ispitane omjere. Važniji nalaz je vremenska podjela: na novijim letovima model postiže ROC AUC od 0,71, što je realnija procjena za upotrebu u aplikaciji. Sljedeća iteracija ispituje korelacije između atributa i uticaj izostavljanja povezanih atributa.

# Dio 4 - Iteracija 4: korelacija atributa

Povezanost ulaznih atributa i uticaj njihovog izostavljanja na Avinor model

Model koristi 12 atributa, od kojih su neki prirodno povezani: udaljenost zavisi od rute, snijeg je dio padavina, a temperatura zavisi od godišnjeg doba. Povezani atributi mogu nositi istu informaciju, pa je moguće da se neki mogu izostaviti bez gubitka kvaliteta, čime bi model bio jednostavniji. U četvrtoj iteraciji izmjerena je povezanost svih parova atributa, a zatim je model ponovo treniran bez pojedinih atributa i njihovih kombinacija. Sve ostalo je isto kao u iteraciji 3 (podjela 90:10).

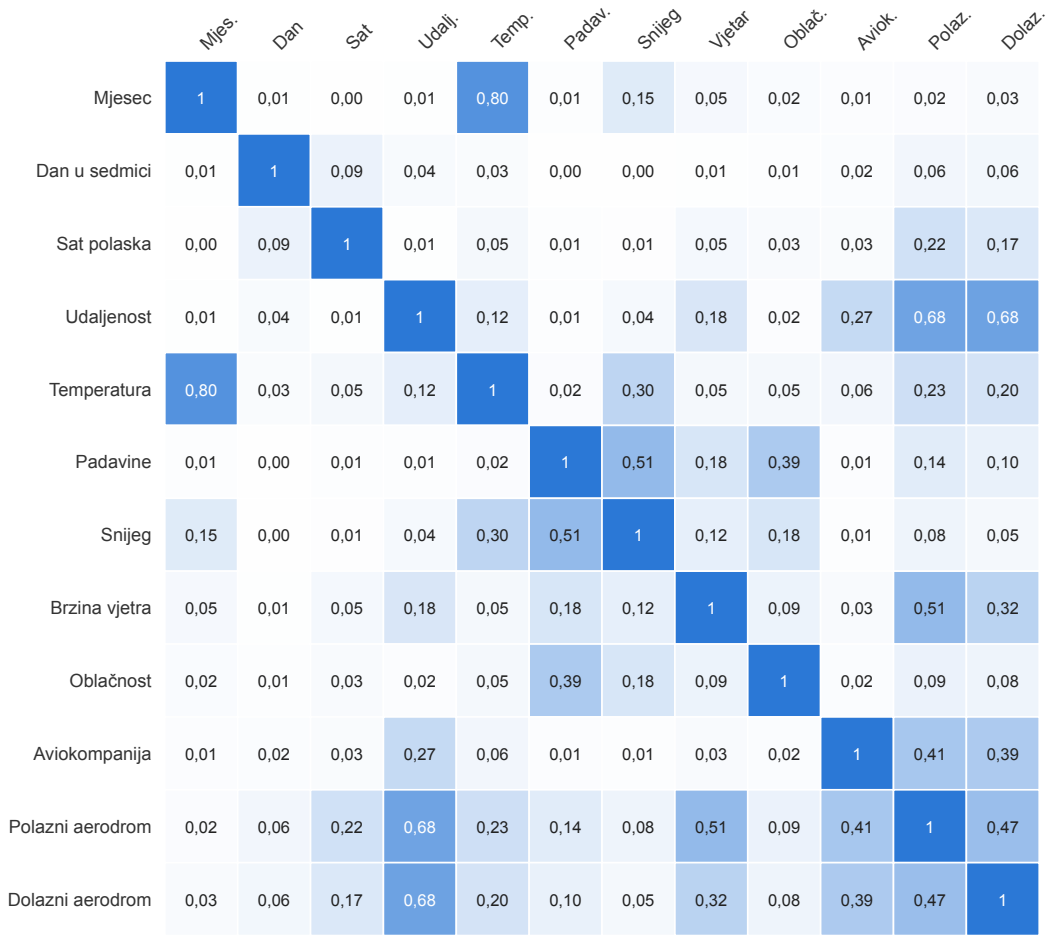
## 24. Mjere povezanosti

Atributi su različitih tipova, pa za svaki par treba odgovarajuća mjera. Sve tri mjere imaju vrijednosti od 0 (nema veze) do 1 (potpuna veza):

- **dva numerička atributa**: apsolutna vrijednost Spearmanove korelacije, koja hvata i nelinearne monotone veze (padavine i snijeg nisu normalno raspodijeljeni, pa je Pearsonova korelacija manje pogodna),
- **dva kategorijska atributa** (aviokompanija, aerodromi): Cramérov V sa korekcijom pristranosti,
- **kategorijski i numerički atribut**: omjer korelacije η, koji pokazuje koliki dio varijacije numeričkog atributa objašnjava kategorija.

Mjesec je cikličan (decembar je do januara), pa linearna korelacija ne vidi sezonsku vezu sa temperaturom (Spearman 0,24). Za taj par je zato korišten η, uz mjesec kao kategoriju. Za numeričke atribute izračunat je i **faktor inflacije varijanse (VIF)**, koji pokazuje koliko je atribut objašnjen kombinacijom svih ostalih. Vrijednosti iznad 5 do 10 uobičajeno ukazuju na problematičnu multikolinearnost.

# 25. Rezultati korelacije




*Slika 9. Povezanost parova atributa (|Spearman|, Cramérov V ili η, zavisno od tipa para)*

| Par atributa | Povezanost | Objašnjenje |
|---|---|---|
| udaljenost - ruta (polazni + dolazni) | 1,00 (η) | udaljenost je izračunata iz koordinata aerodroma, pa je potpuno određena rutom |
| mjesec - temperatura | 0,80 (η) | godišnje doba određuje temperaturu |
| udaljenost - dolazni / polazni aerodrom | 0,68 / 0,68 (η) | svaki aerodrom ima tipične udaljenosti ruta: iz Osla prosječno 334 km, a sa malih aerodroma na sjeveru oko 50 km |
| brzina vjetra - polazni aerodrom | 0,51 (η) | prosječni vjetar je 4,9 km/h u Sandanu (fjord), a 27,4 km/h na Røstu (otvoreno more) |
| padavine - snijeg | 0,51 (Spearman) | u Open-Meteo podacima snijeg je dio ukupnih padavina |
| polazni - dolazni aerodrom | 0,47 (V) | mreža ruta: svaki aerodrom leti na mali broj odredišta |
| aviokompanija - polazni / dolazni aerodrom | 0,41 / 0,39 (V) | Norwegian i SAS lete gotovo samo na ruti Oslo - Molde, a Air Leap i DAT na ruti Oslo - Røros |
| padavine - oblačnost | 0,39 (Spearman) | padavine dolaze iz oblaka |
| temperatura - snijeg | 0,30 (Spearman) | snijeg pada samo na niskim temperaturama |

*Tabela 20. Najjače povezani parovi atributa*

| Atribut | Mjes. | Dan | Sat | Udalj. | Temp. | Padav. | Snijeg | Vjetar | Oblač. |
|---|---|---|---|---|---|---|---|---|---|
| VIF | 1,06 | 1,02 | 1,02 | 1,05 | 1,11 | 1,33 | 1,29 | 1,07 | 1,06 |

*Tabela 21. Faktor inflacije varijanse za numeričke atribute*

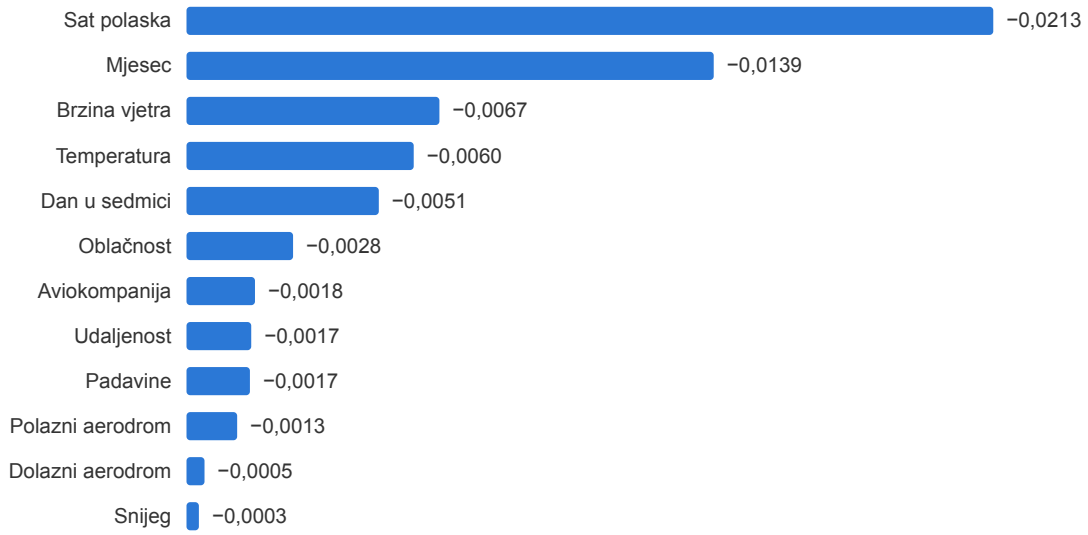
Svi VIF-ovi su ispod 1,4, pa među numeričkim atributima nema jake linearne multikolinearnosti. Najjače veze su između numeričkih i kategorijskih atributa (udaljenost i ruta, vjetar i aerodrom) i nelinearne su (mjesec i temperatura). Kandidati za izostavljanje su atributi čiju informaciju u velikoj mjeri već nose drugi: **udaljenost** (ruta), **snijeg** (padavine i temperatura), **oblačnost** (padavine), **aviokompanija** (aerodromi) i **temperatura** (mjesec).

## 26. Izostavljanje pojedinačnih atributa

Model je treniran 12 puta, svaki put bez jednog atributa, i to na istih 5 nasumičnih podjela 90:10 kao osnovni model. Promjena ROC AUC je računata za svaku podjelu posebno, pa je razlika između modela pouzdanija od poređenja prosjeka.

| Model | Veza sa ciljem | Balansirana tačnost | ROC AUC | Promjena AUC | Prepoznato značajnih kašnjenja | Prepoznato otkazivanja |
|---|---|---|---|---|---|---|
| **Svi atributi (iteracija 3)** | - | **33,61 %** | **0,748** | - | **5,5 %** | **12,0 %** |
| bez: sat polaska | 0,083 | 32,18 % | 0,727 | −0,0213 | 4,0 % | 10,4 % |
| bez: mjesec | 0,051 | 32,68 % | 0,734 | −0,0139 | 4,6 % | 10,3 % |
| bez: brzina vjetra | 0,116 | 32,13 % | 0,741 | −0,0067 | 5,4 % | 7,4 % |
| bez: temperatura | 0,129 | 33,15 % | 0,742 | −0,0060 | 5,3 % | 11,0 % |
| bez: dan u sedmici | 0,026 | 33,27 % | 0,743 | −0,0051 | 5,2 % | 11,5 % |
| bez: oblačnost | 0,086 | 33,49 % | 0,745 | −0,0028 | 5,6 % | 11,6 % |
| bez: aviokompanija | 0,022 | 33,37 % | 0,746 | −0,0018 | 5,5 % | 11,3 % |
| bez: udaljenost | 0,023 | 33,50 % | 0,746 | −0,0017 | 5,6 % | 11,6 % |
| bez: padavine | 0,104 | 33,43 % | 0,746 | −0,0017 | 5,6 % | 11,4 % |
| bez: polazni aerodrom | 0,049 | 33,19 % | 0,746 | −0,0013 | 5,3 % | 10,8 % |
| bez: dolazni aerodrom | 0,050 | 33,64 % | 0,747 | −0,0005 | 5,8 % | 11,7 % |
| bez: snijeg | 0,175 | 33,47 % | 0,747 | −0,0003 | 5,6 % | 11,6 % |

*Tabela 22. Model bez po jednog atributa (prosjek za 5 podjela; „veza sa ciljem“ je η ili V između atributa i klase)*




*Slika 10. Pad ROC AUC kada se atribut izostavi (veći pad znači važniji atribut)*

Izostavljanje **bilo kojeg** atributa u prosjeku smanjuje ROC AUC. Najveći gubitak donosi izostavljanje sata polaska (−0,021) i mjeseca (−0,014). Bez brzine vjetra model prepoznaje samo 7,4 % otkazivanja umjesto 12,0 %. Atributi povezani sa drugima gube najmanje: bez snijega ROC AUC pada za samo 0,0003, a bez udaljenosti za 0,0017. Snijeg je pri tome atribut sa **najjačom** pojedinačnom vezom sa ciljem (0,175). Ta informacija ipak nije izgubljena kada se snijeg izostavi, jer je model nadoknađuje iz padavina i temperature. Upravo to je posljedica korelacije.

## 27. Izostavljanje kombinacija atributa

| Model | Balansirana tačnost | ROC AUC | Promjena AUC (prosjek) | Promjena AUC (najbolja podjela) | Prepoznato značajnih kašnjenja | Prepoznato otkazivanja |
|---|---|---|---|---|---|---|
| **Svi atributi (iteracija 3)** | **33,61 %** | **0,748** | - | - | **5,5 %** | **12,0 %** |
| bez: udaljenost, snijeg | 33,37 % | 0,746 | −0,002 | −0,001 | 5,2 % | 11,5 % |
| bez: udaljenost, aviokompanija | 33,37 % | 0,745 | −0,003 | −0,002 | 5,5 % | 11,2 % |
| bez: snijeg, oblačnost | 33,47 % | 0,745 | −0,003 | −0,002 | 5,4 % | 11,8 % |
| bez: udaljenost, snijeg, aviokompanija | 33,31 % | 0,745 | −0,003 | −0,002 | 5,3 % | 11,2 % |
| bez: udaljenost, snijeg, oblačnost, aviokompanija | 33,30 % | 0,743 | −0,005 | −0,004 | 5,6 % | 11,2 % |
| bez: padavine, snijeg | 32,07 % | 0,738 | −0,009 | −0,008 | 3,3 % | 11,5 % |
| bez: udaljenost, snijeg, oblačnost, aviokompanija, temperatura | 32,38 % | 0,734 | −0,014 | −0,009 | 3,9 % | 10,7 % |

*Tabela 23. Model bez kombinacija povezanih atributa (prosjek za 5 podjela)*

Ni jedna kombinacija ne poboljšava model. Promjena ROC AUC je negativna čak i u najboljoj od 5 podjela, pa pad nije slučajan. Gubitak raste sa brojem izostavljenih atributa: bez udaljenosti i snijega −0,002, bez četiri atributa −0,005, a bez svih pet povezanih atributa −0,014.

Najjasniji primjer je par **padavine i snijeg**. Kada se izostavi samo jedan od njih, gubitak je mali (−0,0017 odnosno −0,0003), jer drugi nosi zajedničku informaciju. Kada se izostave oba, ROC

AUC pada za 0,009, balansirana tačnost za 1,54 procentna poena, a prepoznata značajna kašnjenja sa 5,5 % na 3,3 %. Povezani atributi su, dakle, međusobno zamjenjivi, ali nisu suvišni kao par.

### 27.1. Pregled: testirano izostavljanje svih varijabli

Testirano je izostavljanje **svih 12 varijabli** modela, svake posebno, kao i izostavljanje svih povezanih varijabli zajedno. Ukupno je trenirano 95 modela:

| Test | Broj modela | Rezultat |
|---|---|---|
| Izostavljanje svake od 12 varijabli, jedne po jedne (tabela 22) | 12 × 5 = 60 | bez svake varijable ROC AUC je u prosjeku niži (od −0,0003 bez snijega do −0,0213 bez sata polaska); viši je bio samo u 2 od 60 pokretanja, po jednom bez snijega i bez dolaznog aerodroma, i to manje od jedne standardne devijacije |
| Izostavljanje kombinacija povezanih varijabli (tabela 23) | 7 × 5 = 35 | ROC AUC niži u 35 od 35 pokretanja |
| **Izostavljanje svih 5 povezanih varijabli odjednom** (udaljenost, snijeg, oblačnost, aviokompanija, temperatura) | 5 | model sa preostalih 7 atributa: ROC AUC 0,734 (−0,014), balansirana tačnost 32,38 % (−1,23 p.p.), prepoznato značajnih kašnjenja 3,9 % i otkazivanja 10,7 % |

*Tabela 24. Pregled svih testova izostavljanja varijabli*

Izostavljanje svih pet povezanih varijabli odjednom daje najveći gubitak od svih kombinacija, jednak gubitku bez mjeseca. Balansirana tačnost je u prosjeku bila neznatno viša samo bez dolaznog aerodroma (+0,03 p.p.), što je manje od slučajnog odstupanja između podjela (0,21 p.p.). Nijedna varijabla, dakle, ne može se izostaviti uz pouzdano poboljšanje modela.

## 28. Odluka

Zadržano je **svih 12 atributa**, a model iz iteracije 3 ostaje konačni model. Kod aplikacije nije mijenjan. Razlozi:

- testirano je izostavljanje svih 12 varijabli i svih povezanih varijabli zajedno, a svako izostavljanje u prosjeku smanjuje ROC AUC; u kombinacijama je ROC AUC niži u svakom pokretanju,
- XGBoost je otporan na povezane atribute: stablo odlučivanja pri svakoj podjeli bira jedan od povezanih atributa, pa korelacija ne destabilizuje model kao kod linearne regresije, a niski VIF-ovi potvrđuju da multikolinearnost nije problem,
- izostavljanje ne bi pojednostavilo upotrebu aplikacije: udaljenost se računa automatski iz aerodroma, a vremenski podaci se preuzimaju iz prognoze.

Ako bi u budućnosti bio potreban jednostavniji model (npr. bez ručnog unosa udaljenosti), najmanji gubitak donosi izostavljanje **udaljenosti i snijega** (ROC AUC −0,002).

## 29. Zaključak iteracije 4

Među atributima postoje umjerene do jake veze, prije svega između udaljenosti i rute, mjeseca i temperature, vjetra i aerodroma te padavina i snijega. Linearne multikolinearnosti među numeričkim atributima nema. Testirano je izostavljanje svih 12 varijabli, pojedinačno i u kombinacijama, a bez svih pet povezanih varijabli ROC AUC pada sa 0,748 na 0,734. Eksperimenti sa izostavljanjem pokazali su da povezani atributi mogu djelimično zamijeniti jedan drugog, ali da svaki ipak donosi dio informacije koju drugi nemaju, pa njihovo izostavljanje samo pogoršava model. Konačni model zato ostaje sa svih 12 atributa: tačnost 83,3 %, balansirana tačnost 34,3 % i ROC AUC 0,751.